

算法复现工程：Darwinian Memory System (DMS)

参考论文：[Darwinian Memory: A Training-Free Self-Regulating Memory System for GUI Agent Evolution](#)

一、项目总览与复现目标

本项目旨在复现前沿论文《Darwinian Memory》中提出的达尔文记忆系统 (DMS)。该系统通过引入生物进化论中的“适者生存”机制，解决了动态 GUI Agent 在长期任务中容易遭遇的上下文污染和意图颗粒度不匹配问题。

复现核心目标： 依据论文的数学模型与逻辑，在 **AndroidWorld** 动态基准测试环境中完整实现 DMS 的三大核心机制，并使用轻量级多模态大模型验证系统进化对任务成功率的提升。

二、实验环境与模型基线设定

为保证复现的严谨性与工程的可行性，本次考核对测试场景和底层驱动模型做如下硬性规定：

1. 动态测试环境：AndroidWorld

你必须使用与原论文一致的 **AndroidWorld** (Rawles et al., 2024) 框架作为基础环境，部署并在本地或服务器上运行 Live Android Emulator。为了平衡复现的严谨性与个人算力/时间的限制，对测试集范围提出**阶梯式要求**：

- **首选目标 (Preferred - 完整 Split 评测)：** 建议在 AndroidWorld 的一个完整的标准测试集 (Split / Mini-benchmark) 上进行评估。如果受限于时间无法跑满 116 个任务，请至少覆盖全部 **20 个真实应用场景**，每个 App 随机采样 1-2 个任务进行集中测试。这是验证 DMS 系统是否具备跨应用泛化能力的最佳方式。
- **最低底线 (Minimum Acceptable - 核心任务评测)：** 如果因显存或推理速度限制，绝对无法完成大规模评测，你**最低必须挑选 3-5 个最具代表性的长序列复杂任务**。你需要在报告中明确说明未跑完全集的原因，并详细论证这几个任务为何足以证明 DMS 的全部核心机制。

2. 底层视觉语言模型 (VLM) 选择

为了适配单人开发与算力限制，我们要求你**选用参数量在 7B~8B 级别的开源多模态大模型** (原论文使用了 Qwen2.5-VL-72B 等)。

- **推荐模型：** Qwen2.5-VL-7B-Instruct 或同等级别的开源 VLM。
- **基线对比 (Baselines)：**
 - **Baseline A：** 纯 Zero-shot VLM (无记忆机制)。
 - **Baseline B：** 传统静态记忆系统 (按时间顺序直接追加历史交互轨迹，不做修剪)。
 - **DMS (复现目标)：** 搭载你实现的达尔文记忆系统的同一 VLM。

三、核心算法开发任务

你必须严格按照论文的设计实现以下机制：

1. **分层记忆架构 (Hierarchical Memory)：** 实现“意图级”与“动作级”经验的解耦、保存与组装。
2. **效用驱动的自然选择 (Utility-driven Selection)：**
 - 依据论文设定，实现记忆单元生存价值 (**Survival Value**) 的数学计算逻辑。
 - 必须包含环境反馈 (如任务完成度、无效点击率等) 对生存价值的奖惩计算。
3. **动态淘汰机制 (Dynamic Pruning)：** 设定合理的阈值与清理周期，将低价值

的过时经验从 Prompt Context 中安全移除，实现自我调节。

四、交付物清单与实验指标

请提交一份包含以下内容的压缩包或 GitHub 私有仓库链接：

1. **完整源码**：包含 AndroidWorld 的接入代码、DMS 核心逻辑以及模型调用管道。
2. **自动化运行脚本**：能够一键启动你所选定测试集 (Split 或指定的 3-5 个任务) 并打印执行日志。
3. **复现技术报告 (README / PDF)**：这是评估的重中之重。
 - **机制映射**：代码中哪些部分实现了 Survival Value 和 Pruning? 请指明。
 - **核心指标对比**：请提供图表证明你的系统在多次尝试 (Trials) 中实现了“进化”。必须包含：
 - ◆ **任务成功率 (Success Rate, SR) 演变**：如果跑了完整 Split，请展示整体平均指标；如果是少量任务，请展示单个任务随 Trial 增加的收敛过程。
 - ◆ **Token 消耗量 / 执行步数**的下降趋势 (验证修剪机制的有效性)。
 - ◆ **记忆库大小 (Memory Size)** 随时间的动态变化曲线。
 - **Gap 分析**：受限于模型尺寸 (7B vs 72B)，你是否观察到了与原论文不同的现象？你是如何通过 Prompt 工程或参数调整来弥补模型能力差距的？